



PART 04

第四章 随机变量的数字特征

——协方差和相关系数



数学期望和方差是两个重要的数字特征，分别表示**单个随机变量**的平均值和离散程度。

对于多维随机变量，人们自然可以用各个分量的数学期望和方差来表示他们的中心位置和波动性的大小，但是人们除了考虑各个分量自身的特性外，还常常对各个量之间的关系感兴趣。

本节讨论反映两个变量之间关系的数字特征：协方差和相关系数。





若 DX 、 DY 存在, 则有

$$D(X \pm Y) = DX + DY \pm 2E[(X - EX)(Y - EY)]$$

且当 X 和 Y 独立时, 有 $D(X \pm Y) = DX + DY$

即: 若 X 和 Y 独立, 则 $E[(X - EX)(Y - EY)] = 0$

从而有结论: 若 $E[(X - EX)(Y - EY)] \neq 0$, 则 X 和 Y 不独立。

这说明: $E[(X - EX)(Y - EY)]$ 表达了 X 与 Y 之间的某种关系。

协方差





定义1 设 (X, Y) 为二维随机变量, 它的分量的数学期望 $E(X)$ 和 $E(Y)$ 存在, 若 $E[(X-EX)(Y-EY)]$ 存在, 则称它为 X 与 Y 的协方差, 记为 $Cov(X, Y)$. 即

$$Cov(X, Y) = E[(X - EX)(Y - EY)]$$

协方差越大说明同向程度越高; 协方差越小说明反向程度越高



协方差的计算

(1) 若二维离散型随机变量 (X, Y) 的联合分布律为

$$P\{X=x_i, Y=y_j\}=p_{ij} \quad i, j=1, 2, \dots$$

且 $Cov(X, Y)$ 存在, 则

$$Cov(X, Y) = E[(X - EX)(Y - EY)] = \sum_{i=1}^{\infty} \sum_{j=1}^{\infty} (x_i - E(X))(y_j - E(Y))p_{ij}$$

(2) 若二维连续型随机变量 (X, Y) 的密度函数为 $f(x, y)$

$$Cov(X, Y) = E[(X - EX)(Y - EY)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - E(X))(y - E(Y))f(x, y)dx dy$$

协方差的计算

$$(3) \text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$\begin{aligned} \text{证明: } \text{Cov}(X, Y) &= E\{[X - E(X)][Y - E(Y)]\} \\ &= E\{XY - XE(Y) - YE(X) + E(X)E(Y)\} \\ &= E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y) \\ &= E(XY) - E(X)E(Y) \end{aligned}$$

可见, 若 X 与 Y 独立, $\text{Cov}(X, Y) = 0$ 。



例1.设：随机变量 X 和 Y 的联合概率分布为

$X \backslash Y$	-1	0	1
0	0.06	0.18	0.16
1	0.08	0.32	0.20

求 X 和 Y 的协方差。

解： $Cov(X,Y)=E(XY)-E(X)E(Y)$

$$E(XY)=0 \times (-1) \times 0.06 + 0 \times 0 \times 0.18 + 0 \times 1 \times 0.16$$

$$+ 1 \times (-1) \times 0.08 + 1 \times 0 \times 0.32 + 1 \times 1 \times 0.20 = 0.12$$



另外, X 和 Y 的边缘分布律分别为

X	0	1	Y	-1	0	1
P	0.4	0.6	P	0.14	0.5	0.36

所以 $EX = 0 \times 0.4 + 1 \times 0.6 = 0.6$

$$EY = -1 \times 0.14 + 0 \times 0.5 + 1 \times 0.36 = 0.22$$

$$Cov(X, Y) = E(XY) - E(X)E(Y) = 0.12 - 0.6 \times 0.22 = -0.012$$





例2. 设: (X, Y) 在圆域 $D = \{(x, y): x^2 + y^2 \leq r^2 \ (r > 0)\}$ 上服从均匀分布, 求 $Cov(X, Y)$ 。

解: 易知 (X, Y) 的联合概率密度为 $f(x, y) = \begin{cases} \frac{1}{\pi r^2}, & x^2 + y^2 \leq r^2 \\ 0, & x^2 + y^2 > r^2 \end{cases}$

$$\text{所以 } EX = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xf(x, y) dx dy = \iint_{x^2 + y^2 \leq r^2} x \cdot \frac{1}{\pi r^2} dx dy = 0$$

$$EY = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} yf(x, y) dx dy = \iint_{x^2 + y^2 \leq r^2} y \cdot \frac{1}{\pi r^2} dx dy = 0$$

$$E(XY) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xyf(x, y) dx dy = \iint_{x^2 + y^2 \leq r^2} xy \cdot \frac{1}{\pi r^2} dx dy = 0$$

所以 $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$ 。此题表明, $Cov(X, Y)$ 等于 0, 但 X 与 Y 不独立。



定理1 若 X 和 Y 为随机变量, 且他们的方差 $D(X)$, $D(Y)$ 存在, 则 $X+Y$ 的方差存在, 且 $D(X+Y) = DX + DY + 2Cov(X, Y)$

推论1 若 $X_1, X_2, \dots, X_n$ 为 n ($n \geq 2$) 个方差存在随机变量, 则 $\sum_{i=1}^n X_i$ 的方差存在, 且

$$D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n D(X_i) + 2 \sum_{i < j} Cov(X_i, X_j)$$



协方差具有以下简单的性质

性质1 $Cov(X, a) = 0$ 。

性质2 $Cov(X, Y) = Cov(Y, X)$ 。

性质3 $Cov(X, X) = D(X)$ 。

性质4 $Cov(aX, bY) = abCov(X, Y)$

性质5 $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

性质6 若 X, Y 的协方差 $Cov(X, Y)$ 存在, 则 $E(XY) = E(X)E(Y) + Cov(X, Y)$

例4 设随机变量 $X_1, X_2, \dots, X_n (n > 1)$ 独立同分布, 且它们共同的方差为 $\sigma^2 > 0$, 令 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, Y_1 = X_1 - \bar{X}, Y_n = X_n - \bar{X}$. 求 $D(Y_1)$ 以及 $\text{Cov}(Y_1, Y_n)$ 。

解: 由方差的性质可得:

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n DX_i = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n}$$

$$\text{又易知 } \text{Cov}(X_1, \bar{X}) = \text{Cov}\left(X_1, \frac{1}{n} \sum_{i=1}^n X_i\right) = \text{Cov}\left(X_1, \frac{1}{n} X_1 + \frac{1}{n} \sum_{i=2}^n X_i\right)$$



$$\begin{aligned} \text{Cov}(X_1, \bar{X}) &= \text{Cov}\left(X_1, \frac{1}{n}X_1 + \frac{1}{n}\sum_{i=2}^n X_i\right) = \text{Cov}\left(X_1, \frac{1}{n}X_1\right) + \text{Cov}\left(X_1, \frac{1}{n}\sum_{i=2}^n X_i\right) \\ &= \frac{1}{n}\text{Cov}(X_1, X_1) + \frac{1}{n}\sum_{i=2}^n \text{Cov}(X_1, X_i) = \frac{1}{n}D(X_1) + \frac{1}{n}\sum_{i=2}^n 0 = \frac{\sigma^2}{n} \end{aligned}$$

同理有 $\text{Cov}(X_n, \bar{X}) = \frac{\sigma^2}{n}$

所以

$$D(Y_1) = D(X_1 - \bar{X}) = D(X_1) + D(\bar{X}) - 2\text{Cov}(X_1, \bar{X}) = \sigma^2 + \frac{\sigma^2}{n} - \frac{2\sigma^2}{n} = \frac{n-1}{n}\sigma^2$$





由协方差的性质可得

$$\begin{aligned} \text{Cov}(Y_1, Y_n) &= \text{Cov}(X_1 - \bar{X}, X_n - \bar{X}) = \text{Cov}(X_1, X_n) - \text{Cov}(X_1, \bar{X}) - \text{Cov}(X_n, \bar{X}) + \text{Cov}(\bar{X}, \bar{X}) \\ &= 0 - \text{Cov}(X_1, \bar{X}) - \text{Cov}(X_n, \bar{X}) + D(\bar{X}) = 0 - \frac{\sigma^2}{n} - \frac{\sigma^2}{n} + \frac{\sigma^2}{n} = -\frac{\sigma^2}{n} \end{aligned}$$





协方差衡量了 X 和 Y 之间协同变化的关系。但它的大小还受 X 与 Y 本身量纲的影响。

例如：考察： $Y=X$, $Y=2X$.

直观上，常数2不应影响他们的变化趋势。但协方差却发生了变化。

但此时协方差却发生了变化，如下：

$$\text{Cov}(Y, 2X) = 2\text{Cov}(Y, X)$$

为了消除度量单位对协方差值的影响，把 X 、 Y 标准化后再求协方差，这就相关系数。



随机变量 X 、 Y 的标准化变量分别为

$$X^* = \frac{X - E(X)}{\sqrt{D(X)}} \quad \text{和} \quad Y^* = \frac{Y - E(Y)}{\sqrt{D(Y)}}$$

$$\text{Cov}(X^*, Y^*) = E\{[X^* - E(X^*)][Y^* - E(Y^*)]\} = E(X^* Y^*)$$

$$= E\left[\frac{X - E(X)}{\sqrt{D(X)}} \frac{Y - E(Y)}{\sqrt{D(Y)}}\right] = \frac{E\{[X - E(X)][Y - E(Y)]\}}{\sqrt{D(X)}\sqrt{D(Y)}}$$

$$\text{Cov}(X^*, Y^*) = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$



定义2 设随机变量 X 和 Y 的方差存在, 且 $D(X)>0, D(Y)>0$, 称

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)D(Y)}}$$

为随机变量 X 和 Y 的相关系数, 记为 ρ_{XY} , 在不致引起混淆时, 简记为 ρ 。

注意: ρ_{XY} 是一个无量纲的量。

定义3 若随机变量 X 与 Y 的相关系数 $\rho_{XY}=0$, 则称 X 和 Y 不相关;
若 $\rho_{XY}>0$, 则称 X 和 Y 正相关; 若 $\rho_{XY}<0$, 则称 X 和 Y 负相关。



$$\text{当 } Y=X \text{ 时, } \rho_{XY} = \frac{\text{Cov}(X, X)}{\sqrt{D(X)D(X)}} = \frac{D(X)}{D(X)} = 1$$

$$\text{当 } Y=2X \text{ 时, } \rho_{XY} = \frac{\text{Cov}(X, 2X)}{\sqrt{D(X)D(2X)}} = \frac{2D(X)}{2D(X)} = 1$$

$$\text{当 } Y=bX+a \text{ 时, } b>0 \quad \rho_{XY} = \frac{\text{Cov}(X, bX+a)}{\sqrt{D(X)D(bX+a)}} = \frac{bD(X)}{bD(X)} = 1$$

$$b<0 \quad \rho_{XY} = -1$$

问 a, b 应如何选择, 可使 $a + bX$ 最接近 Y , 接近程度如何来衡量?

设 $e = E[(Y - (a + bX))^2]$

则 e 可用来衡量 $a + bX$ 近似表达 Y 的好坏程度,

当 e 的值越小, 表示 $a + bX$ 与 Y 的近似程度越好,

确定 a, b 的值使得 e 达到最小。


$$e = E[(Y - (a + bX))^2]$$

$$= E(Y^2) + b^2 E(X^2) + a^2 + 2abE(X) - 2bE(XY) - 2aE(Y).$$

将 e 分别关于 a, b 求偏导数, 令其等于0, 得

$$\begin{cases} \frac{\partial e}{\partial a} = 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial e}{\partial b} = 2bE(X^2) - 2E(XY) + 2aE(X) = 0 \end{cases}$$



$$\begin{cases} \frac{\partial e}{\partial a} = 2a + 2bE(X) - 2E(Y) = 0 \\ \frac{\partial e}{\partial b} = 2bE(X^2) - 2E(XY) + 2aE(X) = 0 \end{cases}$$

解得: $b_0 = \frac{Cov(X,Y)}{D(X)}, a_0 = E(Y) - E(X) \frac{Cov(X,Y)}{D(X)}$

将 a_0, b_0 代入 e , 用 $a_0 + b_0X$ 来近似 Y , 最小误差为

$$\min_{a,b} e = E\{[Y - (a_0 + b_0X)]^2\} = (1 - \rho_{XY}^2)D(Y)$$



用 $a_0 + b_0 X$ 来近似 Y , 最小误差

$$\min_{a,b} e = E\{[Y - (a_0 + b_0 X)]^2\} = (1 - \rho_{XY}^2) D(Y)$$

(1) $|\rho_{XY}| \leq 1$

证明: $\min_{a,b} e = E\{[Y - (a_0 + b_0 X)]^2\} = (1 - \rho_{XY}^2) D(Y) \geq 0$

$$\text{又} \because D(Y) \geq 0 \quad 1 - \rho_{XY}^2 \geq 0$$

$$\therefore |\rho_{XY}| \leq 1.$$