



PART 06

第六章 数理统计的基本概念


——抽样分布





引入了总体和样本的概念后，数理统计中的统计推断问题就归结为，根据来自总体的样本，对总体的分布或分布中的参数等进行统计推断。我们可从样本去认识总体。







数理统计的重要任务之一就是**通过样本推断总体的特性**。但是由于样本中所含总体信息较为分散，有时显得杂乱无章，一般不宜直接用于统计推断。



因此，为将这些分散在样本中的有关总体的信息集中起来以反映总体的各种特征，常常要把样本中的信息进行整理、加工、提炼，集中样本中的有用信息，针对不同的研究问题构造样本的适当函数，再利用样本的函数进行统计推断。





例. 从某厂生产的自行车头盔中抽取10件进行检测, 结果是前3件为不合格品, 后面7件为合格品, 依此估计不合格品率 p 。

分析: 总体为 $X \sim b(1, p)$, $0 < p < 1$, 样本为 $X_1, X_2, \dots, X_{10}$

样本提供的信息为

(1) 10次试验中1出现的次数, 即: 不合格品的个数;

(2) 不合格品在哪次试验中出现。

不重要

如何利用这些数据信息来估计未知参数。





定义 设 $X_1, X_2, \dots, X_n$ 为来自总体 X 的样本, $T(X_1, X_2, \dots, X_n)$ 是样本 $X_1, X_2, \dots, X_n$ 的函数, 且不含任何未知参数, 则称 $T(X_1, X_2, \dots, X_n)$ 是统计量。

若 $x_1, x_2, \dots, x_n$ 是相应于样本 $(X_1, X_2, \dots, X_n)$ 的样本值, 则称 $T(x_1, x_2, \dots, x_n)$ 是 $T(X_1, X_2, \dots, X_n)$ 的观察值。

说明

1. 统计量是不含未知参数的样本的函数。
2. 统计量既然依赖于样本, 而后者又是随机变量, 即统计量是随机变量的函数, 故统计量是随机变量。





例. 设 $X_1, X_2, \dots, X_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 其中 μ 未知, σ^2 已知, 下列随机变量中哪些是统计量。

- (1) $\frac{1}{n} \sum_{i=1}^n X_i$ (2) $\frac{1}{n} \sum_{i=1}^n X_i - \mu$ (3) $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2$
(4) $\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2$ (5) $X_{(n)} = \max\{X_1, X_2, \dots, X_n\}$ (6) $X_1 + X_2$

答: (1) (3) (5) (6) 是统计量, (2) (4) 不是





设 $X_1, X_2, \dots, X_n$ 为来自总体 X 的一个样本, $x_1, x_2, \dots, x_n$ 是这一样本的观察值, 定义如下常用统计量。

1. 样本均值 $\frac{1}{n} \sum_{i=1}^n X_i$ 反映了总体均值 EX 的信息。

2. 样本 k 阶 (原点) 矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots$
反映了总体 k 阶(原点)矩 EX^k 的信息。





3. 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 反映了总体方差 DX 的信息。

4. 样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$ 反映了总体标准差 $\sqrt{DX}$ 的信息。

5. 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 2, 3, \dots$
反映了总体标准差 $E[(X - E(X))^k]$ 的信息。





注意： B_2 和 S^2 的区别。

它们的观察值分别为 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ $a_k = \frac{1}{n} \sum_{i=1}^n x_i^k, k=1, 2, \dots$

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad b_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, k=2, 3, \dots$$

仍分别称为样本均值，样本 k 阶（原点）矩，样本方差，样本标准差，样本 k 阶中心矩。





6. 设 $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 将 $X_1, X_2, \dots, X_n$ 按照从小到大排列为

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

称 $(X_{(1)}, X_{(2)}, \dots, X_{(n)})$ 为 $X_1, X_2, \dots, X_n$ 的顺序统计量。

$X_{(k)}, 1 \leq k \leq n$ 为第 k 个顺序统计量;

$X_{(1)} = \min_{1 \leq i \leq n} X_i = \min(X_1, X_2, \dots, X_n)$ 为最小顺序统计量;

$X_{(n)} = \max_{1 \leq i \leq n} X_i = \max(X_1, X_2, \dots, X_n)$ 为最大顺序统计量;

$R = X_{(n)} - X_{(1)}$ 为样本极差, 反映了样本观察值的最大波动程度;





$$\tilde{X} = \begin{cases} X_{(\frac{n+1}{2})}, & n = 2m+1, \\ \frac{1}{2}(X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}), & n = 2m. \end{cases}$$

称为样本中位数，它是把样本分为两部分，而样本中位数恰好是分界线。





统计量是样本 $X_1, X_2, \dots, X_n$ 的函数，而样本是随机变量。因此，统计量也是随机变量，统计量的分布称为抽样分布。

研究统计量的性质和评价一个统计推断的优良性，取决于抽样分布的性质。

近代统计学的创始人之一，英国统计学家费歇(*R.A. Fisher*)把抽样分布、参数估计和假设检验列为统计推断的三个中心内容。因此寻求抽样分布的理论和方法很重要。



抽样分布 { 精确抽样分布 (小样本问题中使用)
渐近分布 (大样本问题中使用)

精确抽样分布: $\forall n$, 统计量 $g(X_1, X_2, \dots, X_n)$ 的分布都可求出.

渐近分布:

统计量 $g(X_1, X_2, \dots, X_n)$ 精确分布不能求出, 或者很复杂. 求 $n \rightarrow \infty$ 的极限分布

本节给出在数理统计中占重要地位的三大分布: χ^2 分布, t 分布, F 分布及其几个重要的抽样分布定理。

例: 设总体 X 的分布形式未知, $E(X)=\mu$, $D(X)=\sigma^2$, $(X_1, X_2, \dots, X_n)$ 为 X 的一样本。则 $X_1, X_2, \dots, X_n$ 独立同分布且 $E(X_i)=\mu$, $D(X_i)=\sigma^2$ ($i=1, 2, \dots, n$)

求证: $E(\bar{X})=\mu$, $D(\bar{X})=\frac{\sigma^2}{n}$, $E(S^2)=\sigma^2$

证明
$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu = \mu$$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$$

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2)$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$= \sum_{i=1}^n X_i^2 - 2\bar{X} \sum_{i=1}^n X_i + \sum_{i=1}^n \bar{X}^2 = \sum_{i=1}^n X_i^2 - 2n\bar{X}^2 + n\bar{X}^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2$$

$$E(S^2) = E\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)\right] = \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2) \right]$$

$$= \frac{1}{n-1} \left[\sum_{i=1}^n (\sigma^2 + \mu^2) - n(\sigma^2/n + \mu^2) \right] = \sigma^2$$

定义1 设 $X_1, X_2, \dots, X_n$ 是来自总体 $N(0,1)$ 的样本, 则称统计量

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$$

服从自由度 (Degree of freedom) 为 n 的 χ^2 分布。记为: $\chi^2 \sim \chi^2(n)$

其中: n 表示独立随机变量的个数。

概率密度为
$$f(x) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$



$$f(x) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$


其中：伽玛函数 $\Gamma(\alpha)$ 通过下述积分定义

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0$$

特别地，当 $n=2$ 时， $\chi^2(2)$ 分布的概率密度

$$f(x) = \begin{cases} \frac{1}{2} e^{-\frac{x}{2}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

期望为2的指数分布



χ^2 分布的性质

1. 设 $X_1, X_2, \dots, X_n$ 相互独立, 都服从正态分布 $N(\mu, \sigma^2)$, 则

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$$

证明: 由 $X_i \sim N(\mu, \sigma^2)$ 且独立, 得 $\frac{X_i - \mu}{\sigma} \sim N(0, 1)$ 且相互独立

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$$

2. 设 $X \sim \chi^2(n)$, 则 $E(X) = n$, $D(X) = 2n$ 。

证明: 存在 $X_i \sim N(0,1)$, $i=1,2,\dots,n$ 且相互独立, 使得 $X = \sum_{i=1}^n X_i^2$

则有 $E(X) = E\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n E(X_i^2) = n$

$$D(X) = D\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n D(X_i^2) = 2n$$

$$E(X_i) = 0, E(X_i^2) = D(X_i) = 1$$

$$E(X_i^4) = \int_{-\infty}^{+\infty} x^4 \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = 3$$

$$D(X_i^2) = E(X_i^4) - [E(X_i^2)]^2 = 3 - 1 = 2$$

3. 设 $X_1 \sim \chi^2(n_1)$, $X_2 \sim \chi^2(n_2)$, 且 X_1, X_2 相互独立, 则 $X_1 + X_2 \sim \chi^2(n_1 + n_2)$

证明: 由 χ^2 分布的定义知:

$$X_1 = U_1^2 + U_2^2 + \cdots + U_{n_1}^2 \quad X_2 = V_1^2 + V_2^2 + \cdots + V_{n_2}^2$$

其中, $U_i \sim N(0,1)$, $i=1, 2, \dots, n_1$, 且相互独立

$V_j \sim N(0,1)$, $j=1, 2, \dots, n_2$, 且相互独立

又由于 X_1, X_2 相互独立, 则 U_i 与 V_j 相互独立

$$\therefore X_1 + X_2 = U_1^2 + U_2^2 + \cdots + U_{n_1}^2 + V_1^2 + V_2^2 + \cdots + V_{n_2}^2 \sim \chi^2(n_1 + n_2)$$

χ^2 分布的可加性

推广: 设 $X_i \sim \chi^2(n_i)$, $i=1, 2, \dots, k$, 且相互独立, 则 $\sum_{i=1}^k X_i \sim \chi^2(\sum_{i=1}^k n_i)$



例1. 设总体 $X \sim N(0,1)$, $X_1, X_2, \dots, X_6$ 为来自总体 X 的样本, 记

$$Y = (X_1 + X_2 + X_3)^2 + (X_4 + X_5 + X_6)^2$$

试确定常数 c , 使 cY 服从 χ^2 分布。

解: $X_1 + X_2 + X_3 \sim N(0,3)$, $X_4 + X_5 + X_6 \sim N(0,3)$

$$(X_1 + X_2 + X_3)/\sqrt{3} \sim N(0,1) \quad (X_4 + X_5 + X_6)/\sqrt{3} \sim N(0,1)$$

且上述两个标准正态随机变量相互独立, 故

$$\left(\frac{X_1 + X_2 + X_3}{\sqrt{3}}\right)^2 + \left(\frac{X_4 + X_5 + X_6}{\sqrt{3}}\right)^2 = \frac{Y}{3} \sim \chi^2(2)$$

因此 $c=1/3$



例2. 设总体 X 服从指数分布 $E(\lambda)$, $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 证明

$$T = 2\lambda(X_1 + X_2 + \dots + X_n) = 2n\lambda\bar{X} \sim \chi^2(2n)$$

证明: 知 $X_1, X_2, \dots, X_n$ 独立同分布, 且都服从 $E(\lambda)$, 其密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

求得 $2\lambda X_1$ 的密度函数为 $f(x) = \begin{cases} \frac{1}{2} e^{-\frac{1}{2}x}, & x > 0 \\ 0, & x \leq 0 \end{cases}$

恰好是自由度为2的 χ^2 分布。